

EntreMentes

Relatório

Extração de Padrões

Mineração de Dados · Projeto Interdisciplinar

DSM 6º Semestre · FATEC Franca

AUTORES

Gabriel Fillip

Leonardo Cássio

DATA

Maio

2026

1

Introdução e Contexto

O **EntreMentes** é uma plataforma de monitoramento de saúde mental e bem-estar acadêmico para estudantes universitários. Os usuários registram diariamente métricas como horas de sono, tempo de tela, estresse acadêmico, frequência de exercício físico e humor percebido.

A etapa de **Extração de Padrões** tem como objetivo identificar automaticamente **perfis comportamentais** nos dados dos estudantes — grupos de indivíduos com características similares de bem-estar — sem que esses grupos precisem ser definidos manualmente por especialistas. Trata-se de um problema de **aprendizado de máquina não supervisionado**.

2

Dataset Utilizado

Fonte	Volume	Features
Kaggle — Student Mental Health & Academic Performance	1.800 registros	6 features numéricas

Após o pré-processamento (**preprocessing.py**), foram selecionadas **6 features numéricas** com correspondência direta com os campos coletados pelo app. Todas foram normalizadas para a escala **[0, 1]** via **MinMaxScaler**.

Feature	Descrição	Escala Original
SleepHours	Horas de sono por noite	0 – 12 h
ScreenTime	Horas de tela por dia	0 – 12 h
ExerciseFreq	Dias de exercício por semana	0 – 7 dias
AcademicStress	Nível de estresse acadêmico	0 – 10
PHQ9	Score de depressão (Patient Health Q.)	0 – 27
GAD7	Score de ansiedade generalizada	0 – 21

3

Algoritmos Utilizados

3.1 K-Means Clustering — Algoritmo Principal

O **K-Means** é um algoritmo de clustering particional não supervisionado. Dado um número K de grupos, o algoritmo itera entre atribuição de amostras ao centroide mais próximo (distância euclidiana) e recalcule dos centroides como média das amostras atribuídas, até convergência.

Parâmetro	Valor	Justificativa
K	4	Cotovelo + Silhouette — ver Seção 5

init	k-means++	Centroides iniciais diversificados, evita mínimos locais
n_init	20	20 inicializações; retorna menor inércia (WCSS)
random_state	42	Semente fixa — reproducibilidade total

3.2 Árvore de Decisão — Extração de Regras (complementar)

Após o K-Means rotular cada estudante, um **DecisionTreeClassifier** (max_depth=3) foi treinado sobre as mesmas features normalizadas, com os rótulos K-Means como variável alvo. O objetivo **não** é criar novos grupos, mas **extrair regras IF-THEN interpretáveis** para usuários e profissionais de saúde.

```
IF PHQ9_norm <= 0.37 AND AcademicStress_norm <= 0.45
THEN perfil = Equilibrado
```

4 Justificativa da Escolha dos Algoritmos

Por que K-Means?

Critério	Justificativa
Natureza do problema	Sem rótulos pré-definidos → problema de <i>descoberta de padrões</i> (não supervisionado)
Tipo de dado	K-Means otimizado para features numéricas contínuas — exato formato das 6 features normalizadas
Eficiência	Complexidade $O(n \cdot k \cdot d \cdot i)$ — processa 1.800×6 features em segundos, sem hardware especializado
Interpretabilidade	Centroide = vetor de médias → "perfil típico" de cada grupo em todas as dimensões
Produção	Classificação de novos usuários $O(k \cdot d)$ por predição, serializável via joblib para API REST

Por que não outros algoritmos?

Algoritmo	Limitação para este contexto
DBSCAN	Classifica periféricos como <i>ruído</i> (sem cluster) — inaceitável em produção onde todo usuário precisa de um perfil. Hiperparâmetros eps/min_samples de difícil calibração comportamental.
Hierárquico (Agglomerative)	Custo $O(n^2)$ de memória e sem modelo serializável para classificar novas amostras em tempo real — inviável em produção.

Gaussian Mixture (GMM)	Requer estimativa de matrizes de covariância completas — menos estável com 1.800 amostras. Interpretação dos parâmetros menos direta para contexto clínico.
-------------------------------	---

5 Determinação do K Ideal

Dois métodos complementares foram utilizados para justificar **K=4**: o Método do Cotovelo analisa a queda da inércia (WCSS), enquanto o Silhouette Score mede a qualidade da separação entre clusters. K=2 apresentaria silhouette marginalmente superior, mas produziria apenas 2 grupos — insuficiente para a granularidade necessária.




Figura 1 — Método do Cotovelo (esq.) e Silhouette Score por K (dir.) · K=4 destacado em ambos os métodos

6 Passos Realizados

1	Carregamento dos dados Leitura do <code>features_kmeans.csv</code> com 1.800 amostras e 6 features normalizadas [0,1].
2	Determinação do K Cálculo da inércia e silhouette para K de 2 a 9 via Método do Cotovelo e Silhouette Score. Decisão: K=4 .
3	Treinamento do K-Means <code>KMeans(K=4, init='k-means++', n_init=20, random_state=42)</code> . Modelo final com inércia e silhouette score registrados.
4	Rotulagem dos perfis Análise dos centroides com heurística: score = sono + exercício – estresse – PHQ9 – GAD7 – tela×0.5 . Clusters ordenados do mais ao menos saudável: Equilibrado, Rotina Saudável, Sob Pressão, Em Alerta .
5	Visualizações Projeção PCA 2D, Radar Chart, distribuição por perfil e Heatmap de centroides normalizados.
6	Extração de regras <code>DecisionTreeClassifier(max_depth=3)</code> treinado sobre X com rótulos K-Means. Geração de regras IF-THEN.

- 7

Análise detalhada
Média, mínimo e máximo das features *originais* (não normalizadas) por cluster para interpretação clínica.
- 8

Serialização
Modelo salvo em `modelo_kmeans.pkl` via `joblib`, contendo modelo, features, perfis e métricas.

7

Resultados Obtidos

4	~285	~0.12	1.800
Clusters (K)	Inércia (WCSS)	Silhouette Score	Amostras treino




Figura 2 — Distribuição de estudantes por perfil comportamental (1.800 total)

Visualizações de Perfil




Figura 3 — Radar Chart dos perfis (esq.) e Heatmap de centroides normalizados (dir.)

O Silhouette Score de ~0.12, embora modesto em valor absoluto, é **esperado e aceitável para dados comportamentais humanos**: estados de saúde mental são contínuos e não possuem fronteiras nítidas. A distribuição equilibrada dos clusters (~25% cada) e a separação visual no gráfico PCA confirmam a qualidade do modelo.

A acurácia do Decision Tree sobre os rótulos K-Means foi **superior a 60%**, confirmando que as fronteiras dos clusters são bem definidas nas 3 divisões de profundidade máxima. A feature mais discriminante na raiz é geralmente **PHQ9_norm** ou **AcademicStress_norm** — consistente com a EDA.

8 Integração com o Sistema

Usuário	Registra humor no app	▼
Backend	Node.js → POST /classify	▼
Service	Flask carrega modelo_kmeans.pkl	▼
MinMax	Normaliza features [0,1]	▼
Predict	modelo.predict([vetor])	▼
App	Exibe perfil, métricas e insights	

9 Conclusão

A etapa de Extração de Padrões do EntreMentes aplicou com sucesso dois algoritmos complementares para descoberta e explicação de perfis comportamentais estudantis.

Algoritmo	Papel	Resultado
K-Means (Principal)	Descoberta não supervisionada de perfis comportamentais em dados de bem-estar.	4 clusters com distribuição equilibrada; modelo serializável em produção.
Decision Tree (Complementar)	Extração de regras IF-THEN interpretáveis das fronteiras K-Means.	Acurácia >60%; explicabilidade para usuários e profissionais de saúde.

Perfis Identificados

Equilibrado Sono e exercício adequados, baixo estresse e PHQ9/GAD7.	Rotina Saudável Sono adequado, estresse controlado, indicadores de saúde estáveis.	Sob Pressão Estresse acadêmico alto, PHQ9 e GAD7 elevados, exercício reduzido.	Em Alerta Pior pontuação de bem-estar; PHQ9/GAD7 muito altos — atenção clínica.
---	--	--	---